

# BraTS2020 Veri Seti Üzerinde Beyin Tümörü Segmentasyonu: BasicUNet ve SegResNet'in Performans Analizi

**Resul Berkem AYDEMİR**

Bilgisayar Mühendisliği Bölümü, Eskişehir Osmangazi Üniversitesi

Eskişehir, Türkiye

berkemaydemir@hotmail.com

## Özet:

Bu inceleme, Böbrek ve Böbrek Tümörü Segmentasyonu Mücadelesi (KiTS-2023)[1] çerçevesinde, MONAI platformu kullanılarak gerçekleştirilen bir uygulamanın detaylarını sunmaktadır. Mücadele, katılımcıların üç boyutlu bilgisayarlı tomografi (3D CT) görüntülerini kullanarak, kendi segmentasyon metodolojilerini karşılaştırmalarına olanak tanımaktadır. İlgili makalede, MONAI kütüphanesine ait Auto3DSeg modülünün otomatik segmentasyon kapasitelerinden faydalanarak mücadeleye yapılan katkı ele alınmaktadır. Gerçekleştirilen uygulama, ortalama zar skoru olarak 0.835 ve yüzey zar skoru olarak 0.723 değerlerini elde etmiş, bu başarı ile KiTS 2023 mücadelesinde lider konuma yükselerek birinciliği elde etmiştir[2]. Öte yandan, BraTS veri seti, multimodal manyetik rezonans görüntüleme (MRI) taramaları kullanılarak beyin tümörlerinin segmentasyonu amacıyla oluşturulmuş bir veri setidir. BraTS 2020, çoklu kurumsal MRI taramalarını temel almakta ve esas olarak, görünüş, şekil ve histoloji açısından doğal olarak heterojen yapıdaki gliomlar gibi beyin tümörlerinin segmentasyonuna yoğunlaşmaktadır. Bu segmentasyon görevinin klinik alaka düzeyini artırmak adına, BraTS 2020 ayrıca hasta genel sağkalım oranlarının tahmin edilmesi, psödoprogresyon ile gerçek tümör nüksünün ayırt edilmesi gibi konulara, radyomik özellikler ile derin öğrenme algoritmalarının entegre analizleri aracılığıyla eğilmektedir. Bu makalede, KiTS yarışmasında kullanılan SegResNet metodolojisinin yanı sıra, BraTS veri seti üzerinde uygulanan alternatif iki yöntem olan BasicUNet ve AutoEncoder da incelenmiştir. Bu üç yöntemin sonucunda SegResNet modelinde 0.55 ve BasicUNet modelinde 0.65 Mean dice skorları elde edilmiştir ve metodolojilerin veri seti üzerindeki etkinliği ve uygulanabilirliği değerlendirilmiştir.

**Anahtar Kelimeler:** MONAI, BraTS, beyin tümörü, segmentasyon, SegResNet, BasicUNet

## Abstract:

This review presents details of an application conducted using the MONAI platform within the Kidney and Kidney Tumor Segmentation Challenge (KiTS-2023)[1]. The challenge allows participants to compare their segmentation methodologies using three-dimensional computed tomography (3D CT) images. The article discusses contributions to the challenge leveraging the automatic segmentation capabilities of the Auto3DSeg module from the MONAI library. The application achieved average dice scores of 0.835 and surface dice scores of 0.723, leading to a top position in the KiTS 2023 challenge, securing first place[2]. Additionally, the BraTS dataset is introduced, designed for segmenting brain tumors using multimodal magnetic resonance imaging (MRI) scans. BraTS 2020 focuses primarily on segmenting brain tumors such as gliomas, which naturally exhibit heterogeneous structures in terms of appearance, shape, and histology. To enhance clinical relevance, BraTS 2020 also delves into analyses integrating radiomic features and deep learning algorithms for tasks such as predicting overall survival rates of patients and distinguishing between pseudoprogression and actual tumor recurrence. In this article, besides the SegResNet methodology used in the KiTS competition, alternative method applied to the BraTS dataset, namely BasicUNet, is also examined. These two methods yielded mean dice

scores of 0.55 for SegResNet and 0.65 for BasicUNet evaluating their effectiveness and applicability on the dataset.

**Keywords:** MONAI, BraTS, brain tumor, segmentation, SegResNet, BasicUNet,

## 1. Giriş

Günümüzde, tümörlerin iyi huylu mu yoksa kötü huylu mu olduğunun radyografik metotlarla tespiti giderek zorlaşmaktadır. Yıllık olarak, yaklaşık yarım milyon bireyin böbrek kanseri teşhisi aldığı belirlenirken [2], Amerika Birleşik Devletleri'nde, Ulusal Beyin Tümörü Derneği'nin raporuna göre, yaklaşık 700.000 bireye beyin tümörü tanısı konulmaktadır [4]. Bu durum, tümör görüntülerinin objektif biçimde karakterize edebilecek ve tedavi sonuçlarını öngörebilecek güvenilir sistemlerin gerekliliğini ön plana çıkarmaktadır.

Kidney and Kidney Tumor Segmentation (KiTS) mücadelesi [1], böbrek tümörlerini içeren yüzlerce segmente edilmiş bilgisayarlı tomografi (BT) taramalarından oluşan halka açık bir veri koleksiyonunu muhafaza etmekte ve genişletmektedir. KiTS'23 yarışması, 489 vaka içeren genişletilmiş bir eğitim setini barındırmaktadır [1]. Bu mücadelenin temel amacı, böbrekleri, tümörleri ve kistleri segmente edebilecek otomatize bir metodoloji geliştirmektir. İncelenen makalede MONAI [1] Auto3DSeg yöntemi kullanılmıştır. Auto3DSeg, MONAI'ya özgü bir projedir ve amacı, çeşitli algoritmalar için yaygın 3D segmentasyon iş akışlarının en iyi uygulamalarını sergilemektir. Uzman olmayan kullanıcılar açısından, bu proje, 3D bilgisayarlı tomografi (BT) veya manyetik rezonans görüntüleme (MRI) verileri üzerinde modelleri otomatik olarak eğitmeye başlamak için sadece birkaç satır kod gerektiren bir başlangıç sunmaktadır. Uzman kullanıcılar için ise, Auto3DSeg, MONAI bileşenlerini kullanarak segmentasyon eğitiminde en iyi uygulamaların reçetelerini sağlar. Bu, kullanıcıların en üst düzeyde temel segmentasyon performansı elde etmelerine, bu performansı özelleştirmelerine ve daha ileri düzeyde geliştirmelerine olanak tanır. MONAI'nın temel özellikleri şunlardır [3]:

- 1) Veri Seti İncelemesi: Auto3DSeg, veri setinin yoğunluk, boyut ve aralık gibi özelliklerini analiz ederek takip edecek süreçler için temel oluşturur.
- 2) Algoritma Üretimi: Algoritma dizinleri, ilk veri analizine bağlı olarak otomatik bir şekilde yapılandırılır.
- 3) GPU Entegrasyonu: Yerleşik GPU desteği, modelin eğitilmesi, doğrulanması ve çıkarım süreçlerinin hızlandırılmasını sağlar.
- 4) Hiper-parametre Optimizasyonu: Auto3DSeg, modelin parametrelerini en uygun performans ve doğruluk için ince ayar yapar.
- 5) Model Kümelenmesi: Auto3DSeg, birden fazla modeli oluşturur ve bütünleştirir, bu da doğruluğun ve güvenilirliğin artırılmasına katkıda bulunur.

Beyin tümörü, şu anda hücrelerin tahmin edilemez ve kötü huylu bir parçalanması sonucu meydana gelen büyük bir kanser durumudur. Tıbbi görüntüleme alanında, derin öğrenme alanındaki son iyileştirmeler sağlık sektörünü güçlendirmiştir. Beyin, vücut parçalarımızdaki en hassas organdır. Beyin tümörü, meme kanseri veya akciğer kanseri gibi diğer tümörlere kıyasla oldukça yaygın değildir ancak yine de küresel olarak 10. en büyük ölüm nedeni beyin tümörüdür. Beyindeki tümör, hastaların davranışları üzerinde önemli bir psikolojik etkiye sahiptir. Beyinde veya omurilikteki doku bozulması, beyin tümörünün beyindeki normal aktiviteyi etkilemesine neden olur. Beyin tümörleri iyi huylu ve kötü huylu olarak sınıflandırılmaktadır. İyi huylu tümörler kanser hücreleri içermez ve yavaşça büyür. Genellikle beyinde tek bir bölgede kalırlar, kötü huylu beyin tümörleri ise kanser hücreleri içerir ve hızla büyüyerek beyin ve omuriliğin diğer bölgelerine yayılır. Kötü huylu bir tümör, insanlar için

zararlıdır ve etkilidir. Beyin tümörleri, Dünya Sağlık Örgütü tarafından 1. ve 2. derece düşük dereceli veya 3. ve 4. derece yüksek dereceli olarak sınıflandırılmıştır. Beyin tümörü, CT taramaları ve EEG de dahil olmak üzere birçok yöntemle tespit edilebilir, ancak en başarılı ve yaygın olarak kullanılan yöntem MRI'dir. MRI, vücudun iç yapılarının detaylı resimlerini oluşturmak için güçlü manyetik alanlar ve radyo dalgaları kullanır. MRI, iç organlar hakkında daha doğru bilgiler içerir ve bu nedenle CT görüntüleme veya EEG'den daha verimlidir.

BraTS veri seti, standardize klinik şartlar altında, ancak farklı ekipmanlar ve görüntüleme protokolleri kullanılarak çeşitli kurumlardan elde edilen beyin tümörü mpMRI taramalarının retrospektif bir koleksiyonunu tanımlar. Bu, farklı kurumlar arasındaki çeşitlendirilmiş klinik uygulamaları yansıtan, önemli ölçüde heterojen bir görüntü kalitesine yol açar. Kabul kriterleri, patolojik olarak doğrulanmış tanı ve mevcut MGMT promotör metilasyon durumunu içerir. Her tümör alt bölgesinin yer doğruluk anotasyonları uzman nöroradyologlarca onaylanmış olup, MGMT metilasyon durumu cerrahi beyin tümörü örneğinin laboratuvar analizine dayanır [5]. Makine öğrenimindeki algoritmik değerlendirme paradigmasına uygun olarak, BraTS 2020 yarışmasına dahil edilen veriler eğitim, doğrulama ve test kümeleri olarak bölünmüştür. Yarışma katılımcılarına sadece eğitim verileri için yer doğruluk etiketleri sağlanmakta, doğrulama verileri ise ilişkili bir yer doğruluk olmaksızın katılımcılara sunulmakta ve test verileri katılımcılardan sürekli gizli tutulmaktadır [6].

Bu makale, MICCAI KiTS 2023 Yarışması kapsamında gerçekleştirilen Böbrekler ve Tümörlerin Otomatik 3D Segmentasyonu çalışmasının içeriğini ve metodolojisini irdelemektedir. İncelenen makaledeki bir model olan SegResNet ve başka bir mimari olan BasicUNet modellerinin BraTS2020 veri seti üzerinde beyin tümörü tespitine yönelik uygulamasına odaklanmaktadır. İkinci bölümde, KiTS 2023 Yarışması bağlamında gerçekleştirilen Böbrekler ve Tümörlerin Otomatik 3D Segmentasyonu çalışmasının detaylı bir açıklaması, incelenen çalışmada kullanılan MONAI ile ilgili önceden gerçekleştirilmiş ilgili literatürün kapsamlı bir incelemesi ve BraTS2020 veri setine ilişkin daha önce tamamlanmış çalışmalar ele alınmaktadır. Üçüncü bölüm, BraTS2020 veri setinin ayrıntılı bir tanımıyla, SegResNet ve BasicUNet metodolojisini sunmaktadır. Dördüncü Bölüm, her iki model için bulunan bulguların birbirleri ile kıyaslanarak değerlendirilmesini içerir. Beşinci bölümde sonucun değerlendirilmesi ve alternatifler sunulmaktadır.

## 2. Önceki Çalışmalar

MICCAI KiTS 2023 yarışması kapsamında gerçekleştirilen "Böbrekler ve Tümörlerin Otomatik 3D Segmentasyonu" başlıklı çalışma, MONAI platformunu kullanarak Auto3DSeg açık kaynak projesi aracılığıyla metodolojilerini uygulamıştır. Auto3DSeg, MONAI'de bulunan açık kaynak bileşenlerini kullanarak 3D tıbbi görüntü segmentasyonu için otomatize edilmiş bir çözüm sunar ve araştırmacılara, yüksek performanslı segmentasyon algoritmalarını etkili bir şekilde geliştirme ve uygulama imkânı sağlar. Auto3DSeg'in standart ayarı, kendilerine has eğitim yönergeleri ile SegResNet [7], DiNTS [8] ve SwinUNETR [9,10] olmak üzere üç farklı 3D segmentasyon algoritmasını eğitmektedir. SegResNet ve DiNTS mimarileri, evrimsel sinir ağları (CNN) temeline sahipken, SwinUNETR mimarisi dönüştürücüler (transformers) temel alınarak geliştirilmiştir. Bu algoritmalar beş katlı çapraz doğrulama yöntemi ile eğitilir. Model çıkarım aşamasında, olasılık haritalarının oluşturulması için kayar pencere tekniği (sliding-window scheme) tercih edilir ve bu haritalar orijinal boyutlarına yeniden örneklendirilir, bu da farklı çözünürlüklerde eğitilmiş algoritmaların tahminlerinin bütünleştirilmesini sağlar. Auto3DSeg, minimal kullanıcı girdisi talep ederek, uzman olmayan kullanıcıların dahi etkileyici bir başlangıç performansı elde etmelerine olanak tanır. Sistem, analiz, yapılandırma ve mevcut GPU kaynaklarının optimal kullanımı gibi önemli görevleri üstlenir. Uzman kullanıcılar için, performansı artırmak amacıyla, otomatik değerlerin manuel olarak değiştirilebileceği çeşitli yapılandırma seçenekleri sunulmaktadır. Yarışmayı kazanan bu çalışma, çapraz doğrulama aşamasında üstün performans sergiledikleri tespit edildiği için yalnızca SegResNet ve DiNTS

algoritmalarına ait en iyi model kontrol noktalarını entegre ederek tahminde bulunmuştur. Bununla birlikte, temel Auto3DSeg iş akışına bir dizi minör özelleştirme de uygulanmıştır.

SegResNet, kodlayıcı-çözücü yapısına dayalı semantik bir segmentasyon ağı olup, derin denetim mekanizması içeren U-net tabanlı bir evrişimli sinir ağıdır [7]. Auto3DSeg'in standart SegResNet yapılandırması, beş ayrı seviyede yer alan 1, 2, 2, 4, 4 blokları içeren bir yapılandırmayı temel alır ve görüntü boyutlarını ardışık olarak iki kat azaltırken aynı anda özellik boyutunu artırma stratejisine dayanır. Bu yapıda gerçekleştirilen tüm evrişim işlemleri  $3 \times 3 \times 3$  boyutlarında olup, başlangıç filtre sayısı 32 olarak belirlenmiştir. Kodlayıcı,  $256 \times 256 \times 256$  boyutunda bir giriş bölgesi ile eğitilmiş, çözücü yapısı ise her bir mekânsal seviyede tek bir blok içerecek şekilde kodlayıcıya benzer bir yapıda düzenlenmiştir. Çözücü seviyelerinin her biri, özellik sayısını yarıya indiren ve mekânsal boyutu iki kat artıran ters yönlü evrişim ile başlamakta ve eşdeğer mekânsal seviyedeki kodlayıcı çıktısının eklenmesiyle süreç devam etmektedir. Katman sayısı ve bölge boyutu otomatik olarak yapılandırılmaktadır. Uygulanan arttırma teknikleri, tüm eksenlerde rastgele afin transformasyonlarını, yansımaları, yoğunluk ölçeklemelerini, kaymaları, gürültüyü ve bulanıklığı içermektedir. Dice kaybı fonksiyonundan faydalanılmakta ve bu, tüm derin denetim alt katmanları boyunca toplanmaktadır:

$$Loss = \sum_{i=0}^4 \left( \frac{1}{2^i} \right) Loss(pred, target^{\downarrow})$$

Burada  $1/(2^i)$  ağırlığı, her bir alt katman için küçültülmektedir. Gerekğinde hedef etiketler, karşılık gelen çıktı boyutuna uyacak şekilde en yakın komşu yöntemiyle küçültülmektedir. AdamW optimizasyon algoritması kullanılmakta olup, başlangıç öğrenme oranı  $2e^{-4}$  olarak belirlenmiş ve final döneminde Cosine annealing zamanlayıcısı ile sıfıra indirgenmiştir. Her bir GPU için belirlenen grup boyutu birimdir ve  $1e^{-5}$  ağırlık çürüme düzenlemesi uygulanmıştır. Giriş görüntüleri  $[-54, 242]$  aralığından  $[-1, 1]$  aralığına yeniden ölçeklendirilmiş ve ardından bir sigmoid işlevi uygulanmıştır, bu aralık veri analizi aşamasında otomatik olarak ayarlanmış ve ön plan bölgelerindeki yoğunluk değişikliklerini kapsayacak şekilde düzenlenmiştir.

DiNTS, Yapısal Ağ Topolojisi Arama (Differentiable Network Topology Search) metodolojisini temsil eder ve entegre edilmiş iki katmanlı bir arama ile daha dinamik topolojilerin teşvik edilmesini hedefleyen ileri düzey bir yaklaşımdır. DiNTS, Medical Segmentation Decathlon (MSD) yarışmasında [11] öncü sonuçlar elde ederek kendi alanında üstün bir performans sergilemiştir. Yoğun bağlantılı bir ızgara tabanlı ağ yapısını temel alan DiNTS algoritması hem eğitim hem de çıkarım süreçleri için  $96 \times 96 \times 96$  boyutlarında model girişi ile eğitilmektedir. Otomatik karma hassasiyet (AMP) ve SGD optimizasyon algoritması kullanılmakta, başlangıç öğrenme oranı 0,2 olarak belirlenmiş ve kayıp, Dice ile odak kaybının birleşimi olarak tanımlanmıştır. Veri işleme sürecinde, yoğunluk normalizasyonu, rastgele kırpma, dönme, yakınlaştırma, Gauss yumuşatması, yoğunluk ölçeklendirme ve kaydırma, Gauss gürültüsü ve yansıtma teknikleri kullanılmaktadır. Modelin iyileştirilmesi amacıyla, varsayılan eğitim tarifesıyla önceden eğitilmiş kontrol noktaları, 25 epoch boyunca farklı yama boyutlarıyla ince ayarlanmıştır. Araştırmacıların gözlemleri, büyütülmüş yama boyutunun genellikle model performansını artırdığını göstermektedir. Hesaplama kapasitemizi göz önünde bulundurarak, modelin her katlaması için  $192^3$  ile  $192 \times 192 \times 288$  arasında değişen bir yama boyutu aralığından seçim yapmış ve bu seçim, doğrulama Dice skorlarına dayanarak yapılandırılmıştır.

Auto3DSeg'in ön tanımlı yapılandırması, otomatik olarak kabul edilebilir bir çapraz doğrulama performansı sağlamasına karşın, böbrek bölgesine yönelik kırpma ve sonrasındaki işlemler gibi birtakım özelleştirmeler gerçekleştirilmiştir. 3D BT görüntülerinin tam boyutlarında eğitim yapmak zaman alıcı olduğundan, görüntüler böbrek bölgesine odaklanacak şekilde önceden kırılmıştır. Bu

kırpılmış görüntüler üzerinde eğitim yapmanın iki avantajı bulunmaktadır: ilk olarak, daha küçük görüntülerin RAM'de önbelleğe alınabilmesi eğitim sürecini hızlandırmakta, ikinci olarak, ağ için görevi basitleştirmektedir. Ancak bu yöntemin dezavantajı, ilk etapta böbrekler bölgesinin sınırlayıcı alanın belirlenmesi gerekliliğidir. Böbreklerin sınırlayıcı alan koordinatlarını hesaplamak amacıyla ayrı bir segmentasyon ağı eğitilmiştir. Tüm görevlerde, aynı ağ mimarisi kullanılarak tüm modeller  $0.78 \times 0.78 \times 0.78\text{mm}^3$  BT çözünürlüğünde eğitilmiştir. Modellerin ilk turu, sınırlayıcı alan dedektörü olarak kullanılmak üzere hızlı bir şekilde eğitilmiş ve sonrasında yalnızca böbrekler etrafında kırpılmış bölgeler kullanılarak daha uzun süreli eğitim gerçekleştirilmiştir. Ayrıca, final segmentasyon maskelerine ikili son işlem eklenmiştir: İlk olarak, ön plana dayalı olarak küçük bağlı bileşenler (toplamda 100 vokselin altında) kaldırılmış, ikinci olarak, bazı tümör bölgelerinin dış hatları düzeltilmiştir. Eğitim sürecinde, küçük bir görüntü setinde, ağın çok etiketli bir görev olarak eğitilmesi nedeniyle tümör etiketinin tahminlerinde küçük bir kist etiketi kenarı (1-2 voksel) oluştuğu gözlemlenmiştir. Tümörün tanım itibarıyla bir "kistik" dış hattı olamayacağından, bu tür durumlar basit bir ikili son işleme ile düzeltilmiştir. Son olarak, eğitim sırasında ağ giriş yamasının boyutu SegResNet için  $256 \times 256 \times 256$ 'ya, DiNTS için  $192 \times 192 \times 288$ 'e çıkarılmış, bu hem eğitimi hızlandırmış hem de çapraz doğrulama performansını az da olsa artırmıştır.

Rastgele beş katlı bölme işlemimize dayanarak, kat başına ortalama zar skorları Tablo 1'de sunulmuştur. Nihai gönderim için 15 modelden oluşan bir ansambl kullanılmıştır: SegResNet'ten 10 model (her bir kat iki defa eğitilmiş) ve DiNTS'ten 5 model. Tablo 1'de yer alan SegResNet A ve B eğitim seansları aynı yapılandırmalara sahiptir.

	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5	Average
SegResNet A	0.8997	8739	0.8923	0.8911	0.8892	0.88924
SegResNet B	0.8995	8773	0.8913	0.889	0.8865	0.88872
DINTS	0.8910	8647	0.8806	0.8752	0.8822	0.8767

**Tablo 1.** KiTS 2023 Yarışmasında Böbreklerin ve Tümörlerin Segmentasyonu Sonuçları [2]

Bu yarışmanın finalindeki gizli meydan okuma veri seti üzerinde, incelenen makaledeki çalışma 0,835 olarak ölçülen ortalama Dice skoru ile diğer katılımlar arasında birinci sırayı elde etmiştir [2].

Kullanacağımız veri setinin yarışması olan BraTS 2020 yarışmasını kazanan ekip BraTS 2020 yarışmasının segmentasyon görevinde nnU-Net kullanımı gerçekleştirmiştir. Değiştirilmemiş nnU-Net temel yapılandırması zaten saygın bir sonuç elde etse de BraTS'e özgü son işleme, bölge bazlı eğitim, daha agresif veri artırma ve nnU-Net iş akışına yönelik bir dizi küçük değişiklikle segmentasyon performansı önemli ölçüde iyileştirmiştir. Bu metodoloji, BraTS 2020 yarışmasında, sırasıyla tüm tümör, tümör çekirdeği ve artan tümör için 88.95, 85.06 ve 82.03 Dice skorları ile ve 8.498, 17.337 ve 17.805 HD95 değerleri ile birinci sırayı elde ederek yarışmayı kazanmıştır [12].

nnU-Net, tam adıyla "no-new-U-Net", tıbbi görüntü segmentasyonu için tasarlanmış bir derin öğrenme çerçevesidir. Fabian Isensee ve ekibi tarafından geliştirilen bu çerçeve, çeşitli tıbbi görüntüleme veri kümelerinde yüksek performanslı segmentasyon modelleri oluşturmak üzere otomatikleştirilmiş bir yapılandırma süreci sunmaktadır. nnU-Net, yalnızca basit UNet benzeri mimarileri kullanmaktadır.

BraTS 2020 için seçilen giriş yama boyutu  $128 \times 128 \times 128$ 'dir. Aşağı örnekleme, katmanlı konvolüsyonlar kullanılarak gerçekleştirilirken, yukarı örnekleme konvolüsyon transpoze olarak uygulanmıştır. Özellik haritası boyutları, mimarinin kodlayıcı kısmında sergilenmektedir. Dekoderdeki özellik haritaları, kodlayıcıyı yansıtmaktadır. Derin denetim için kullanılan yardımcı segmentasyon çıktıları, dekodeerdeki en düşük iki çözünürlük dışındaki tüm düzeylerde dallanmaktadır. nnU-Net, her bir segmentasyon görevi için ağ yapılandırmasını, eğitim prosedürlerini ve veri ön işleme adımlarını otomatik olarak ayarlama yeteneği sayesinde öne çıkar[13].

nnU-Net, U-Net mimarisinin genişletilmiş bir versiyonudur ve aşağıdaki özelliklere sahiptir:

1. Otomatik Yapılandırma: nnU-Net, veri kümelerinin özelliklerine göre ağ yapılandırmasını, öğrenme oranını, toplu iş boyutunu ve diğer hiperparametreleri otomatik olarak ayarlar. Bu, her bir tıbbi görüntüleme görevine özel olarak el ile yapılandırma ihtiyacını ortadan kaldırır.
2. Dinamik Mimariler: nnU-Net, veri setinin özelliklerine bağlı olarak dinamik olarak derinlik, filtre sayısı ve katman boyutlarını ayarlar. Bu, farklı görüntü çözünürlükleri ve boyutlarına sahip veri kümeleri için uygundur.
3. Veri Ön İşleme: nnU-Net, veri normalizasyonu, artırma ve yeniden boyutlandırma gibi ön işleme adımlarını otomatikleştirir, bu da segmentasyon modelinin eğitim sürecini daha etkili hale getirir.
4. Derin Öğrenme Modelleri: nnU-Net, temel olarak U-Net ve U-Net'in çeşitli varyasyonlarını kullanır, ancak bu temel yapılar veriye özgü olarak dinamik bir şekilde ayarlanır.
5. Performans: nnU-Net, Medical Segmentation Decathlon gibi çeşitli yarışmalarda ve görevlerde üst düzey performans sergilemiştir. Bu başarı, nnU-Net'in geniş bir yelpazede tıbbi görüntüleme görevlerinde etkili bir şekilde çalışabildiğini gösterir.

Literatürdeki diğer önceki çalışmalara baktığımızda, genellikle farklı konfigürasyonlara sahip UNet mimarisini kullanan çalışmaları gözlemliyoruz. Bu çalışmaların sonuçları, Dice skorları üzerinden değerlendirilmiş ve sırasıyla tümör, tüm tümör ve tümör çekirdeği için 0.81-0.90, 0.86-0.91, 0.73-0.90 aralıklarında Dice skorları elde edilmiştir. Doğruluk oranı ile değerlendirmeler yapan araştırmacılar, %98.485 ve %99.4 gibi yüksek doğruluk oranları bildirmişlerdir [14-21]. UNet dışında farklı bir yaklaşım olarak CNN kullanımını içeren bir çalışma da mevcuttur; bu çalışma %98'lik bir doğrulama doğruluğu elde etmiştir [22].

Henry ve ekibi U-net mimarisi kullanarak yaptıkları çalışmada, BraTS 2020 için sırasıyla enhance tümör, tüm tümör ve tümör çekirdeği için Dice skorları 0.81, 0.91 ve 0.85; Hausdorff (95%) değerleri 20.6, 4.3 ve 5.7 mm'dir. Ayrıca, final test veri setinde elde edilen performansları, sırasıyla 0.79, 0.89 ve 0.84 Dice ve 20.4, 6.7 ve 19.5 mm Hausdorff (95%) ile Henry ve takımını en iyi on takım arasında konumlandırmıştır. [14].

BharathSimhaReddy Maram ve Pooja Rana, beyin tümörünü tespit etmek için U-Net mimarisini kullanarak, %98,485 oranında bir eğitim doğruluğu elde etmişlerdir. BraTS2020 veri setinde uygulanan diğer mimarilerle yapılan karşılaştırmalarda, özelleştirmelerle zenginleştirilmiş U Net mimarisinin daha üstün sonuçlar sunduğu tespit etmişlerdir. [15].

Haytham ve ekibi çalışmasını, 3D hacimsel veriler üzerinde gerçekleştirilmiş olup, farklı tümör bölgeleri için Dice Similarity Coefficient (DSC) ve Jaccard Similarity Coefficient (JSC) değerleriyle değerlendirilmiştir. Çalışmanın sonuçlarını WT (Whole Tumor) için DSC  $\pm 0.88$ , TC (Tumor Core) için DSC  $\pm 0.87$ , ET (Enhancing Tumor) için DSC  $\pm 0.73$ , WT için JSC  $\pm 0.79$ , TC için JSC  $\pm 0.78$  ve ET için JSC  $\pm 0.59$  olarak raporlamıştır. Bu bulgular, kullanılan pipeline yaklaşımının tümör

segmentasyonunda başarılı bir performans gösterdiğini ve farklı tümör bileşenlerinin doğru bir şekilde sınıflandırıldığını göstermektedir.[16]

Mostafa ve ekibi, beyin tümörü segmentasyonu ve tanısı algoritmalarını geliştirmek amacıyla BraTS veri setini kullanarak derin öğrenme tabanlı bir konvolüsyonel sinir ağı (CNN) modeli geliştirme sürecini uygulamışlardır. Model eğitimi sırasında, kategorik çapraz entropi kayıp fonksiyonu ve Adam optimizasyon algoritması kullanılmıştır. Sonuç olarak, model veri setindeki beyin tümörlerini başarılı bir şekilde tanımlayıp segmente etmiş ve %98'lik bir doğrulama doğruluğu elde etmiştir [17].

Smarta ve ekibi, MRI görüntülerinden beyin tümörlerinin tespiti ve segmentasyonunu gerçekleştirmek üzere, derin öğrenme çerçevesi içerisinde modifiye edilmiş bir U-Net mimarisi geliştirmiştir. Söz konusu model, BRATS 2020 veri kümeleri tarafından sağlanan otantik görüntüler üzerinde değerlendirilmiş ve %99,4 gibi dikkate değer bir test doğruluğu elde etmiştir [18].

Bilgisayar destekli tanı yazılımları, beyin tümörlerinin otomatik segmentasyonunda yardımcı olabilir ve derin öğrenmeye dayalı birçok metodoloji tasarlanmıştır. D-UNet mimarisinde, kodlama veya örnekleme azaltma aşamasında yerel özellikler kaybolur, bu da model daha derine indikçe sürekli öğrenmeye yol açar. Bu makalede, yerel özellikleri korumaya yardımcı olmak için mekansal dikkat tabanlı mekanizma kullanılmıştır. Yeniden tasarlanan mimarinin kodlama yolundaki ek modüller, örnekleme artırma veya kod çözme yolu sırasında birleştirilmiştir. Deneylerde, BraTS 2020 veri setinin tümör çekirdeği (TC), tüm tümör (WT) ve artan tümör (ET) bölgeleri için segmentasyon sonuçları elde edilmiştir. Ortalama zar skorları sırasıyla TC, WT ve ET için 0.9027, 0.8868 ve 0.9067 olarak elde edilmiştir.[19]

Araştırmacılar Aarif Raza ve Mohammad Farukh Hashmi tarafından yürütülen çalışmada, BraTS 2020 kamu veri seti üzerinde yapılan çalışmalar sonucunda elde edilen bulgular raporlanmıştır. Çalışma, önerilen ağ modelinin genel tümör alanında, tümör çekirdeği bölgesinde ve tümör geliştirme alanında ortalama zar değerlerini sırasıyla %88.96, %86.48 ve %84.32 olarak belirlemiştir. Bu sonuçlar, modelin tümör segmentasyonunda başarılı bir performans sergilediğini ve farklı tümör bölgelerinin doğru bir şekilde tanımlandığını göstermektedir.[20]

Araştırmacılar Smarta Sanguia ve ekibi tarafından yürütülen çalışmada, U-Net mimarisi kullanılarak elde edilen segmentasyon sonuçları, tüm tümörler için ortalama zar skorunu 0.9221, tümör çekirdekleri için 0.8760, artan tümörler için 0.8659 ve peritümoral ödem için 0.8362 olarak belirlenmiştir. Bu sonuçlar, U-Net mimarisinin beyin tümörlerinin deteksiyonunda etkili bir yöntem olarak işlev gördüğünü ve farklı tümör bileşenlerinin doğru bir şekilde sınıflandırıldığını göstermektedir.[21]

Araştırmacılar Mostafa, A.M. ve ekibi CNN mimarisiyle tümör çekirdeği, tüm tümör ve artan tümör için sırasıyla ortalama 0.860, 0.908 ve 0.824 zar skoru elde etmişlerdir. Bu bulgular, önerilen derin öğrenme modelinin farklı tümör bileşenlerini doğru bir şekilde tanımlayabildiğini ve tümörlerin görüntüleme teknolojileri üzerindeki etkisini vurgulamaktadır. [22]


### **3. Materyal ve Yöntem**

#### **3.1 BraTS 2020 Veri Seti**

Bu çalışmada kullanılan veri seti, Brain Tumor Segmentation Challenge 2020 tarafından sağlanan BraTS2020 veri setidir. BraTS2020, beyin tümörlerinin otomatik segmentasyonu üzerine yapılan araştırmalarda birincil referans kaynağı olarak kabul edilmektedir. Veri seti, beyin manyetik rezonans görüntülemesi (MRG) taramaları ile uzmanlar tarafından yapılan manuel işaretlemelerin bir kombinasyonundan oluşmaktadır. Toplamda 494 farklı katılımcıya ait MRG görüntüleri bulunmaktadır; bunlardan 369'u eğitim ve 125'i doğrulama veri setlerinde kullanılmıştır. Doğrulama

verileri, her bir katılımcıdan elde edilen T1-ağırlıklı, kontrast artırılmış T1-ağırlıklı, T2-ağırlıklı ve FLAIR görüntülerinden oluşur. Bu görüntüler, Nörogörüntüleme Bilişim Teknolojileri Girişimi tarafından geliştirilen NII dosya formatında kaydedilmiştir. Eğitim verileri, aynı görüntü tiplerini içermekte olup, ek olarak segmentasyon görüntülerini de barındırır. Hem eğitim hem de doğrulama veri setleri için, katılımcıların yaş, hayatta kalma süresi ve reseksiyon kapsamını içeren hayatta kalma bilgileri bir csv dosyasında saklanır. Ayrıca, katılımcıların önceki BraTS veri setlerindeki ID'lerini içeren bir isim haritası dosyası bulunmaktadır.

Gliomlar, yetişkinler arasında en yaygın görülen primer beyin tümörleri olup, çeşitli derecelerde agresiflik ve prognoz sergiler. Standart görüntüleme dizileri arasında T1 ağırlıklı dizi (T1), gadolinyum bazlı kontrast ajanlar ile güçlendirilmiş T1 ağırlıklı dizi (T1Gd), T2 ağırlıklı dizi (T2) ve sıvı zayıflatılmış ters çevrim iyileştirme (FLAIR) dizisi yer alır. Tanımlanabilen dört farklı tümöral alt bölge şunlardır: "artan tümör" (ET), T1'e göre T1Gd'de hipo-intens görünen "artmayan tümör" (NET) ve "nekrotik tümör" (NCR), ve FLAIR dizisinde hiper-intens olan "peritümoral ödem" (ED). Bu alt bölgeler, üç anlamsal olarak ayrılmış tümör komponentine gruplanabilir: ET ilk grubu, ET, NET ve NCR'nin birleşimi "tümör çekirdeği" (TC) bölgesini, ve ED'nin TC'ye eklenmesi "tüm tümör" (WT) bölgesini oluşturur.



Şekil 1. Dört Farklı MR Modalitesi (FLAIR, T1CE, T2, T1)

Şekil 1, BraTS-2020 veri setindeki dört farklı MR modalitesini göstermektedir ve her biri beyin dokusu ve tümör özelliklerinin çeşitli yönlerini vurgulamaktadır. Bu modaliteler FLAIR, T1CE, T2 ve T1 olup, her biri benzersiz bir tanısal amaca hizmet etmektedir. Aşağıda her bir modalitenin ayrıntılı açıklaması bulunmaktadır:

1. FLAIR (Fluid-Attenuated Inversion Recovery): FLAIR görüntüleme, beyin parankimindeki lezyonların görünürlüğünü artırarak beyin omurilik sıvısı (BOS) sinyallerini bastırır. Bu modalite, peritümoral ödem ve beyaz cevher lezyonlarının tespitinde özellikle etkilidir. Veri setindeki FLAIR görüntüsü, patolojik değişikliklerle ilişkili hiperintens bölgelerin net bir şekilde deline edilmesini sağlar ve tümörün yayılımı ve ilişkili ödemin değerlendirilmesi için kritik bilgiler sunar.
2. T1CE (Kontrastlı T1-Ağırlıklı): Kontrast madde (gadolinyum) uygulanmasının ardından elde edilen T1 ağırlıklı görüntüler, kan-beyin bariyeri bozulmalarını görselleştirmek için esastır. Kontrast artışı, anormal vaskülarite ve tümör neovaskülarizasyonu alanlarını vurgular. T1CE modalitesi, aktif tümör bölgelerinin tespiti ve tümör dokusu ile tümörsüz bölgeler arasındaki ayrım için kritik öneme sahiptir, böylece hassas tümör derecelendirmesi ve tedavi planlaması kolaylaşır.
3. T2-Ağırlıklı Görüntüleme: T2-ağırlıklı görüntüler, su içeriğine oldukça duyarlıdır ve ödem, BOS ve tümörlerin kistik bileşenleri gibi bölgelerde yüksek sinyal yoğunluğu sağlar. Bu modalite, beynin genel anatomisini görselleştirmede, gri ve beyaz cevher yapılarını ve gliomlarla ilişkili patolojik değişikliklerin tespitinde önemli rol oynar. Veri setindeki T2




görüntüleri, beyin morfolojisinin kapsamlı bir görünümünü sunar ve tümör sınırlarının ve peritümoral ödemin yayılımının belirlenmesine yardımcı olur.

4. T1-Ağırlıklı Görüntüleme: T1-ağırlıklı görüntüler, beyaz cevher ve gri cevher arasında yüksek kontrast sağlayarak mükemmel anatomik detay sunar. Bu modalite, beyin yapısal bütünlüğünü değerlendirmek ve anormal doku özelliklerine sahip bölgeleri tespit etmek için değerlidir. T1 görüntüleri, çeşitli beyin yapılarını ayırt etmeyi kolaylaştırır ve kontrastlı görüntülerle birlikte patolojik değişikliklerin tespiti için referans olarak kullanılır

"Brain MRI Representations (BraTS-2020)" başlığı ile anotasyonlanmış olan dört modalitenin birleşik görüntüsü, BraTS-2020 veri setinde kullanılan çeşitli görüntüleme tekniklerinin kapsamlı bir görsel temsidir. Her bir alt görüntü, uzamsal yönelimi ve modaliteler arası karşılaştırmayı kolaylaştırmak için ızgara hizalıdır. Bu şekil temsil, beyin tümörlerinin doğru tanı, karakterizasyon ve tedavi planlamasında çok modaliteli görüntülemenin önemini vurgulamaktadır.


Bu dört MR modalitesini entegre ederek, araştırmacılar ve klinisyenler, her bir görüntüleme tekniği tarafından sağlanan tamamlayıcı bilgileri kullanarak glioma özelliklerinin daha doğru ve bütüncül bir anlayışına ulaşabilirler. Bu çok modaliteli yaklaşım, tümör segmentasyonu, tanı ve terapötik müdahalelerin doğruluğunu artırır ve nihayetinde nöro-onkolojik uygulamalarda hasta sonuçlarının iyileştirilmesine katkıda bulunur.

### 3.2 Veri Ön İşleme ve Segmentasyon




Şekil 2. Yüksek Dereceli Gliom (HGG) Segmentasyon Maskeleri ve MR Sekansları.

Şekil 2, BraTS-2020 veri setinden alınan yüksek dereceli gliomların (HGG) beyin manyetik rezonans (MR) görüntülerine uygulanan segmentasyon maskelerini detaylı olarak göstermektedir. Bu şekil, HGG'lerin çeşitli segmentasyon aşamalarını ve her bir aşamada tümörün nasıl tanımlandığını açıklamayı amaçlamaktadır. HGG'ler, hızlı büyüyen ve oldukça agresif olan beyin tümörleridir. Bu tür tümörlerin doğru segmentasyonu, teşhis ve tedavi sürecinde büyük önem taşır. Bu şekilde görüldüğü üzere tüm tümör (WT) tüm renklerdir. Tümör çekirdeği (TC) mavi ve yeşil renklerle gösterilen alandır. Gelişen tümör sadece kırmızı renkle gösterilen alandır.




Şekil 3. Düşük Dereceli Gliom (LGG) Segmentasyon Maskeleri ve MR Sekansları.

Şekil 3, düşük dereceli gliom (LGG) segmentasyonunu detaylı bir şekilde göstermektedir. LGG'ler, daha yavaş büyüyen ve daha az agresif tümörlerdir. Bu nedenle, tedavi yaklaşımları ve cerrahi müdahaleler daha düşük risk taşır. LGG segmentasyon maskesi oluşturmak için ayrılan görüntülerde gelişen tümör kısmı bulunmaz, tüm tümör (WT) tüm renklerde, tümör çekirdeği (TC) mavi renktedir.



Şekil 4. Güçlendirilmiş Tüm Tümör (WT) Görüntüsü


Şekil 4'te, veri artırma işlemleri sonrasında tüm tümörün (Whole Tumor, WT) segmentasyon sonuçları sunulmaktadır. MRI dilimlerinde WT'nin segmentasyonu başarıyla gerçekleştirilmiş olup, uygulanan çeşitli dönüşümler WT'nin tutarlı bir şekilde tanımlanmasına olanak sağlamıştır.



Şekil 5. Güçlendirilmiş Tümör Çekirdeği (TC) Görüntüsü

Şekil 5'te, veri artırma işlemleri sonrasında tümör çekirdeğinin (Tumor Core, TC) segmentasyon sonuçları sunulmaktadır. Görüntüler, MRI dilimlerinin farklı kontrast ve parlaklık seviyelerinde

başarılı bir şekilde normalize edildiğini ve TC'nin segmentasyonunun tutarlı ve belirgin bir şekilde gerçekleştirildiğini göstermektedir.



**Şekil 6.** Güçlendirilmiş Gelişen Tümör (ET) Görüntüsü

Şekil 6'da, veri artırma işlemleri sonrasında elde edilen enhancing tümör (Enhancing Tumor, ET) segmentasyon sonuçları sunulmaktadır. MRI dilimlerine çeşitli dönüşümler uygulanmış ve ET segmentasyonu net bir şekilde tanımlanmıştır. Veri artırma teknikleri, ET segmentasyonunun doğruluğunu artırarak, daha güvenilir ve tutarlı sonuçlar elde edilmesine olanak sağlamıştır.

### 3.3 SegResNet

SegResNet, özellikle 3D tıbbi görüntü segmentasyonu için tasarlanmış derin öğrenme modellerinden biridir. Bu model, derin konvolüsyonel sinir ağları ve residual ağların (ResNet) birleşimi ile oluşturulmuş olup, hem yüksek doğruluk hem de verimli öğrenme süreçleri sağlar. SegResNet modeli, hem düşük hem de yüksek seviyeli özelliklerin etkin bir şekilde yakalanmasını ve kullanılmasını sağlar.

SegResNet modeli, beş ana bileşenden oluşur: aktivasyon modülü, giriş konvolüsyonu (convInit), aşağı örnekleme katmanları (down\_layers), yukarı örnekleme katmanları (up\_layers) ve son konvolüsyon katmanı (conv\_final). Bu bileşenler, modelin giriş verisini işleyerek yüksek kaliteli segmentasyon sonuçları elde etmesini sağlar.

Modelin başlangıcında, aktivasyon fonksiyonu olarak ReLU (Rectified Linear Unit) kullanılır. ReLU, modelde doğrusal olmayanlık ekleyerek öğrenmeyi ve özellik çıkarmayı daha etkili hale getirir. "inplace=True" argümanı, bellek verimliliğini artırmak için aktivasyonun yerinde uygulanmasını sağlar.

Giriş konvolüsyonu, modelin ilk katmanıdır ve giriş verisinin temel özelliklerini çıkarmak için kullanılır. Bu katman, 4 kanallı bir girişi alarak 16 kanallı bir çıktı üretir. Konvolüsyon işlemi, 3x3x3 boyutlarındaki bir çekirdek kullanılarak gerçekleştirilir ve padding ile giriş ve çıkış boyutlarının korunması sağlanır. Ayrıca, bu katmanda bias kullanılmamaktadır.

Aşağı örnekleme katmanları, giriş verisinin uzamsal boyutlarını azaltarak ve kanal derinliğini artırarak yüksek seviyeli özelliklerin çıkarılmasını sağlar. Bu katmanlar, ardışık olarak düzenlenmiş dört ana bloktan oluşur. İlk blokta, kimlik (identity) bağlantısı ve bir residual blok (ResBlock) bulunur. ResBlock, iki konvolüsyon katmanı, iki grup normalizasyon (GroupNorm) katmanı ve ReLU aktivasyon fonksiyonundan oluşur. Grup normalizasyonu, batch normalizasyonuna alternatif olarak, küçük batch boyutlarında daha iyi performans gösterir. İkinci blokta, 16 kanallı giriş verisini 32 kanala çıkaran bir konvolüsyon katmanı ve iki ResBlock bulunur. Konvolüsyon işlemi, 3x3x3 çekirdek kullanılarak ve stride=2 ile gerçekleştirilir, bu da uzamsal boyutların yarıya indirilmesini sağlar. Bu blokta da grup normalizasyonu ve ReLU aktivasyonu kullanılır. Üçüncü blok, 32 kanallı giriş verisini 64 kanala çıkaran bir konvolüsyon katmanı ve iki ResBlock içerir. Dördüncü blok ise, 64 kanallı giriş verisini 128 kanala çıkaran bir konvolüsyon katmanı ve beş ResBlock içerir. Bu bloklar da benzer şekilde grup normalizasyonu ve ReLU aktivasyonu ile donatılmıştır.

Yukarı örnekleme katmanları, modelin uzamsal boyutlarını geri yüklerken kanal derinliğini azaltarak, orijinal giriş boyutlarına ve özelliklerine en yakın şekilde yeniden oluşturur. Bu katmanlar, ardışık olarak düzenlenmiş üç ana bloktan oluşur. İlk blokta, 128 kanallı giriş verisini 64 kanala indiren bir konvolüsyon katmanı ve bir UpSample katmanı bulunur. UpSample katmanı, ölçek faktörü olarak (2.0, 2.0, 2.0) kullanarak, uzamsal boyutları iki katına çıkarır. Bu blok, residual bloklarla birlikte çalışarak verinin yüksek çözünürlükte yeniden yapılandırılmasını sağlar. İkinci blokta, 64 kanallı giriş verisini 32 kanala indiren bir konvolüsyon katmanı ve bir UpSample katmanı bulunur. Üçüncü blok ise, 32 kanallı giriş verisini 16 kanala indiren bir konvolüsyon katmanı ve bir UpSample katmanı içerir. Bu bloklar, residual bloklarla birlikte çalışarak verinin yüksek çözünürlükte yeniden yapılandırılmasını sağlar.

Son konvolüsyon katmanı, modelin çıktı katmanıdır ve nihai segmentasyon haritasını üretir. Bu katman, grup normalizasyonu ve ReLU aktivasyonu ile başlar, ardından 1x1x1 boyutlarında bir konvolüsyon çekirdeği kullanarak 16 kanallı girişi 3 kanallı bir çıktıya dönüştürür. Bu katman, modelin segmentasyon çıktısını üreterek, giriş verisinin doğru bir şekilde sınıflandırılmasını sağlar.

Modelin sonunda, aşırı uyumu önlemek için bir Dropout3d katmanı bulunur. Bu katman, %20 olasılıkla nöronları devre dışı bırakarak modelin genelleme yeteneğini artırır ve eğitim sırasında daha sağlam bir öğrenme süreci sağlar.

SegResNet mimarisi, residual bloklar ve grup normalizasyonu gibi ileri düzey teknikler kullanarak, derin ağlarda karşılaşılan gradyan kaybolması problemini çözer ve öğrenme sürecini iyileştirir. Residual bloklar, doğrudan bağlantılar ekleyerek, gradyanların daha derin katmanlara etkili bir şekilde iletilmesini sağlar. Grup normalizasyonu, özellikle küçük batch boyutlarında, öğrenme sürecini stabilize eder ve modelin performansını artırır. Konvolüsyon ve konvolüsyon transpose katmanları, verinin uzamsal boyutlarını ve kanal derinliklerini değiştirerek, yüksek çözünürlüklü segmentasyon sonuçları elde edilmesini sağlar. Dropout katmanı ise aşırı uyumu önleyerek modelin genelleme yeteneğini artırır.

SegResNet modeli, dikkatlice tasarlanmış konvolüsyonel, normalizasyon ve aktivasyon katmanları ile 3D tıbbi görüntü segmentasyonu için güçlü bir mimari sunar. Model, residual bloklar ve grup normalizasyonu gibi tekniklerle donatılmış olup, hem düşük hem de yüksek seviyeli özelliklerin etkin bir şekilde yakalanmasını ve kullanılmasını sağlar. Bu özellikler, modelin tıbbi görüntüleme uygulamalarında yüksek doğrulukta segmentasyon sonuçları elde etmesini mümkün kılar. SegResNet, verinin hem uzamsal hem de özellik boyutlarını etkili bir şekilde işleyerek, yüksek kaliteli segmentasyon haritaları üretir ve bu da onu birçok farklı tıbbi görüntüleme uygulaması için uygun hale getirir.

### 3.4 BasicUNet

BasicUNet, U-Net mimarisinin bir türevidir ve hacimsel (volumetrik) veriler üzerinde etkili bir şekilde çalışmak üzere uyarlanmıştır. BasicUNet modeli, giriş verisinin temsili kapasitesini artırmak ve segmentasyon çıktısını yüksek doğrulukla oluşturmak amacıyla tasarlanmış çok katmanlı bir konvolüsyonel sinir ağıdır. Proje modelinin ana bileşenleri başlangıç konvolüsyon bloğu, aşağı örnekleme blokları, yukarı örnekleme blokları ve son konvolüsyon katmanıdır.

Başlangıç konvolüsyon bloğu, giriş verisinin temsili kapasitesini artırmak amacıyla iki ardışık konvolüsyon katmanından oluşur. İlk konvolüsyon katmanı, 4 kanallı bir girişi alarak 32 kanallı bir çıktı üretir ve bu işlem 3x3x3 boyutlarındaki bir konvolüsyon çekirdeği kullanılarak gerçekleştirilir. Çıktı, InstanceNorm3d ile normalize edilir. InstanceNorm3d, her örneğin mini-batch içindeki özellik haritalarını normalize eder, bu da modelin daha hızlı ve kararlı öğrenmesine yardımcı olur. Aktivasyon için LeakyReLU kullanılır, bu da negatif girişlerde küçük ama pozitif bir gradyan sağlar ve ReLU'nun

neden olduğu ölmekte olan nöron problemini önler. Ayrıca, 0.1 olasılıkla bir dropout katmanı bulunur, bu da aşırı uyumu önlemek için rastgele nöronları devre dışı bırakır. İkinci konvolüsyon katmanı, 32 kanallı giriş boyutunu korur ve benzer şekilde normalize ve aktive edilir.

Aşağı örnekleme yolu, her biri girişin uzamsal boyutlarını azaltırken kanal derinliğini artıran dört hiyerarşik bloktan oluşur. İlk blok, 2x2x2 boyutlarında bir max pooling katmanı içerir ve ardından iki konvolüsyon katmanı bulunur. Her iki katman da 32 çıktı kanalı üretir ve aynı normalizasyon ve aktivasyon şemasını izler. İkinci blokta, max pooling işlemi benzer şekilde uygulanır, ancak konvolüsyon katmanlarının çıkış kanalları 64'e çıkarılır. Üçüncü blokta, ilk konvolüsyon katmanı 96 kanal çıkışı üretirken, ikinci katman bu derinliği korur. Son blokta ise max pooling işlemi uygulanır ve konvolüsyon katmanları 128 kanal çıkışı üretir. Bu yapı, modelin yüksek düzeyde özellikleri yakalamasını sağlar.

Yukarı örnekleme yolu, girişin uzamsal çözünürlüğünü orijinal boyutlarına geri yüklerken aşağı örnekleme yolundaki yüksek düzeyde özellik haritalarını birleştirir. Bu yol, dört bloktan oluşur. İlk blok, 2x2x2 konvolüsyon transpose katmanı ile yukarı örnekleme işlemi yaparak 128 kanalı 64 kanala düşürür. Bu işlem sonrasında yukarı örneklenmiş çıktı, aşağı örnekleme yolundan gelen özelliklerle birleştirilir ve iki konvolüsyon katmanı tarafından işlenir. Her iki katman da 96 kanallı bir çıktı üretir. İkinci blokta, yukarı örnekleme işlemi 48 kanala yapılır ve ardından gelen konvolüsyon katmanları 64 kanallı bir çıktı üretir. Üçüncü blokta, 32 kanala yapılan yukarı örnekleme işlemi sonrasında iki konvolüsyon katmanı 32 kanallı bir çıktı üretir. Son blokta ise 32 kanalı koruyan yukarı örnekleme işlemi sonrasında iki konvolüsyon katmanı 32 kanallı bir çıktı üretir.

Modelin son konvolüsyon katmanı, 1x1x1 boyutlarında bir çekirdek kullanarak 32 kanallı girişi istenen çıktı kanal sayısına indirir. Bu çalışmada, çıktı kanal sayısı 3'tür. Bu katman, segmentasyon haritasının son halini üretir.

BasicUNet mimarisini genel olarak özetlemek gerekirse, 3D görüntü segmentasyonu görevleri için performansı optimize etmek amacıyla çeşitli kritik bileşenleri bir araya getirir. Konvolüsyon katmanları, çeşitli soyutlama seviyelerinde özellik çıkarımı için esastır. InstanceNorm3d, özellik haritalarını normalize etmek için kullanılır ve bu, daha hızlı yakınsamaya ve daha iyi genelleştirmeye yardımcı olur. Dropout katmanı, aşırı uyumu önlemek için %0.1 olasılıkla nöronları rastgele devre dışı bırakır. LeakyReLU aktivasyon fonksiyonu, ağırlık karmaşık desenleri öğrenmesine olanak tanır ve ReLU'nun neden olduğu ölmekte olan nöron problemine karşı önlem alır. Max pooling katmanları, uzamsal boyutları azaltırken en önemli özellikleri korur ve modelin daha verimli öğrenmesini sağlar. Konvolüsyon transpose katmanları, uzamsal boyutları geri yüklerken düşük çözünürlükte çıkarılan özelliklerin yüksek çözünürlükte yeniden inşa edilmesini sağlar.

BasicUNet modeli, dikkatlice tasarlanmış konvolüsyonel, normalizasyon ve aktivasyon katmanları ile 3D görüntü segmentasyonu görevleri için sağlam bir mimari olarak hizmet eder. Hiyerarşik aşağı örnekleme ve yukarı örnekleme yolları, verimli özellik çıkarımı ve yeniden yapılandırma sağlar. Bu da uzamsal hassasiyet ve özellik detaylarının önemli olduğu tıbbi görüntüleme uygulamaları için özellikle uygundur. BasicUNet modeli, tıbbi görüntüleme alanında yüksek doğrulukta segmentasyon sonuçları elde etmek için etkili bir araç olarak ön plana çıkmaktadır.

Her iki model için uzaysal boyutlandırmalar, 3 boyutlu görüntüler işlendiği için 3 olarak belirlenmiştir. Girdi kanalları, 4 tür görüntü girdisi bulunduğu için giriş kanallarının sayısı 4 olarak belirlenmiştir. Çıkış kanalları ise, 3 tür tümör çıktısı vereceği için çıkış kanallarının sayısı 3 olarak belirlenmiştir. Eşit değerlendirme yapılması açısından her iki model de 50 epoch boyunca eğitilmiş ve aynı yöntemlerle

değerlendirilmiştir. Bu sayede, modellerin performanslarının adil ve tarafsız bir şekilde karşılaştırılması sağlanmıştır.

#### 4. Bulgular

Bu bölümde, SegResNet ve BasicUNet modellerinin beyin tümörü segmentasyonu üzerindeki performanslarını karşılaştırmalı olarak değerlendirilmiştir. Her iki modelin farklı sınıflar (TC, WT, ET) için elde ettiği Dice skorları incelenmiş ve model performansları detaylı olarak analiz edilmiştir. performanslarını değerlendirmek için çeşitli metrikler kullanılmıştır. Bu metrikler arasında kesinlik (Precision), duyarlılık (Recall), doğruluk (Accuracy) ve Jaccard indeksi bulunmaktadır. Her bir metrik, modellerin segmentasyon başarımını farklı açılardan ölçerek, hangi modelin daha iyi performans gösterdiğini belirlememizi sağlar.

Sınıf	SegResNet Dice Skoru	BasicUNet Dice Skoru
<b>Ortalama Dice</b>	0.5525	0. 6474
<b>TC (Tumor Core)</b>	0.686646	0.758137
<b>WT (Whole Tumor)</b>	0.52351	0. 623942
<b>ET (Enhancing Tumor)</b>	0.454169	0.533944

**Tablo 2.** Modellerin Sınıflar için Dice Skorları

Ortalama Dice skorları, modelin genel segmentasyon performansını gösteren önemli bir metriktir. SegResNet modelinin ortalama Dice skoru 0.5525 iken, BasicUNet modelinin ortalama Dice skoru 0.6474 olarak hesaplanmıştır. Bu bulgular, BasicUNet modelinin genel segmentasyon performansının SegResNet modeline kıyasla daha iyi olduğunu göstermektedir. Bu üstün performans, BasicUNet'in segmentasyon görevinde daha etkili olduğunu ve daha doğru sonuçlar üretebildiğini göstermektedir.

Tumor Core (TC) segmentasyonunda, SegResNet modeli 0.686646 Dice skoru elde ederken, BasicUNet modeli 0.758137 Dice skoru elde etmiştir. TC, tümörün en yoğun ve kritik bölgesini temsil ettiği için bu sınıfta elde edilen yüksek doğruluk, modelin klinik uygulamalarda güvenilirliğini artırmaktadır. BasicUNet modelinin bu sınıfta daha yüksek bir Dice skoru elde etmesi, tümör çekirdeğinin daha iyi tanımlandığını ve segmentasyon doğruluğunun arttığını göstermektedir. Bu, cerrahi müdahaleler ve tedavi planlaması için önemli bir avantaj sağlamaktadır.

Whole Tumor (WT) segmentasyonunda, SegResNet modeli 0.52351 Dice skoru elde ederken, BasicUNet modeli 0.623942 Dice skoru elde etmiştir. WT, tümörün genel yayılımını içerdiğinden, bu sınıfta elde edilen skorlar tümör sınırlarının doğru belirlenmesi açısından kritiktir. BasicUNet modelinin daha yüksek bir Dice skoru elde etmesi, tümörün genel yapısının daha doğru segmentlendiğini ve tümör sınırlarının daha net belirlendiğini göstermektedir. Bu da modelin tümörün tamamını kapsayan segmentasyon görevlerinde daha başarılı olduğunu işaret etmektedir.

Enhancing Tumor (ET) segmentasyonunda, SegResNet modeli 0.454169 Dice skoru elde ederken, BasicUNet modeli 0.533944 Dice skoru elde etmiştir. ET, kontrast madde uygulaması sonrası daha belirgin hale gelen aktif tümör hücrelerini temsil eder ve doğru segmentasyonu tedavi yanıtını ve prognozunu değerlendirmek için kritiktir. BasicUNet modelinin bu sınıfta daha yüksek bir Dice skoru

elde etmesi, aktif tümör bölgelerinin daha iyi tespit edildiğini ve segmentasyon doğruluğunun arttığını göstermektedir. Bu da tedavi stratejilerinin daha etkili planlanmasına olanak sağlamaktadır.

Genel olarak, BasicUNet modeli, SegResNet modeline kıyasla tüm sınıflarda daha yüksek Dice skorları elde etmiştir. Bu sonuçlar, BasicUNet'in beyin tümörü segmentasyonu görevlerinde daha üstün performans sergilediğini ve daha doğru sonuçlar üretebildiğini göstermektedir.

Metrik	SegResNet	BasicUNet
Precision	0.3333	0.3617
Recall	0.3390	0.6417
Accuracy	0.9726	0.9812
Jaccard	0.3253	0.3559

**Tablo 3.** Modellerin Metrik Verileri

Kesinlik (Precision), doğru olarak segment edilmiş tümör bölgelerinin, model tarafından tümör olarak segment edilen tüm bölgeler içindeki oranını gösterir. Yani, modelin pozitif olarak tahmin ettiği bölgelerin ne kadarının gerçekten pozitif olduğunu ölçer. SegResNet modeli için kesinlik 0.3333 iken, BasicUNet modeli için 0.3617'dir. BasicUNet modeli, kesinlik açısından SegResNet modelinden biraz daha iyi performans göstermektedir. Bu, BasicUNet'in yanlış pozitifleri azaltmada daha etkili olduğunu, yani tümör olmayan bölgeleri yanlışlıkla tümör olarak işaretleme olasılığının daha düşük olduğunu gösterir.

Duyarlılık (Recall), gerçekten tümör olan bölgelerin, model tarafından doğru olarak segment edilen oranını ifade eder. Yani, modelin pozitif olarak tahmin ettiği tüm gerçek pozitiflerin ne kadarını yakalayabildiğini gösterir. SegResNet modeli için duyarlılık 0.3390 iken, BasicUNet modeli için 0.6417'dir. Duyarlılık metriği açısından, BasicUNet modeli SegResNet modelinden belirgin derecede daha iyi performans sergilemektedir. Bu, BasicUNet'in daha fazla sayıda gerçek tümör bölgesini doğru olarak tespit edebildiğini gösterir. Özellikle klinik uygulamalarda, yüksek duyarlılık değeri tümörlerin eksiksiz bir şekilde tespit edilmesi açısından kritik öneme sahiptir.

Doğruluk (Accuracy), tümör segmentasyonunda doğru olarak sınıflandırılan piksel sayısının, toplam piksel sayısına oranını ifade eder. SegResNet modeli için doğruluk 0.9726 iken, BasicUNet modeli için 0.9812'dir. Her iki model de yüksek doğruluk değerlerine sahip olmakla birlikte, BasicUNet modeli burada da SegResNet modelini geçmektedir. Bu, BasicUNet'in genel segmentasyon performansının daha iyi olduğunu ve tümör dışı normal beyin dokusunu segmentasyonda daha doğru bir şekilde tanımlayabildiğini gösterir.

Jaccard İndeksi, kesişim-birleşim oranı olarak bilinen ve iki veri kümesinin ne kadar örtüştüğünü ölçen bir metriktir. Segmentasyon problemlerinde, modelin tahmin ettiği bölgeler ile gerçek bölgelerin ne kadar örtüştüğünü belirler. SegResNet modeli için Jaccard indeksi 0.3253 iken, BasicUNet modeli için 0.3559'dur. Jaccard indeksi açısından da BasicUNet, SegResNet'ten daha üstün performans

göstermektedir. Bu, BasicUNet'in hem tümör segmentasyonunda hem de bu segmentlerin lokalizasyonunda daha başarılı olduğunu ifade eder.

Genel olarak, BasicUNet modelinin beyin tümör segmentasyonunda SegResNet modeline kıyasla daha iyi performans sergilediğini göstermektedir. Precision ve Jaccard indeksi açısından, BasicUNet'in daha yüksek doğruluk ve kesişim-birleşim oranlarına sahip olması, modelin daha doğru ve güvenilir segmentasyonlar üretebildiğini ifade eder. Recall metriğindeki belirgin fark ise, BasicUNet'in tümör bölgelerini eksiksiz tespit etme kabiliyetinin daha yüksek olduğunu göstermektedir.

## 5. Sonuç

Bulgular sonucunda, BasicUNet modelinin beyin tümörü segmentasyonunda SegResNet modeline kıyasla daha üstün bir performans sergilediğini ve özellikle tümörün farklı bileşenlerinin segmentasyonunda daha doğru ve tutarlı sonuçlar verdiğini ortaya koymaktadır. Ancak, her iki modelin de belirli iyileştirmelere ihtiyaç duyduğu ve daha fazla epoch sayısında eğitim yapılarak performanslarının artırılabilceği açıktır..

Model eğitimleri sırasında Google Colab aracılığıyla bir tane A100 kullanılmıştır ve parametre optimizasyonları bu donanıma göre ayarlanmıştır. Eğer daha iyi bir donanıma sahipseniz segmentasyon modellerinin performansını değerlendirmek ve iyileştirmek için deneyebileceğiniz birçok strateji bulunmaktadır. Eğitim sürecinin uzatılması, veri artırımı tekniklerinin kullanılması, farklı algoritmaların ve model mimarilerinin denenmesi, hiperparametre optimizasyonu gibi yaklaşımlar, modelin genel performansını artırmak için etkili olabilir. Bu stratejiler, beyin tümörü segmentasyonunda daha doğru ve güvenilir sonuçlar elde etmeyi sağlayarak, klinik uygulamalarda ve araştırma alanında önemli katkılar sunabilir. Modelin performansını iyileştirmeye yönelik bu öneriler, segmentasyon modellerinin daha başarılı olmasını sağlayacaktır.

## Github Link:

<https://github.com/berkemaydemir/BraTS2020-Segmentation-with-SegResNet-and-BasicUNet>



## 5. Kaynaklar

- [1] Project-monai/monai, <https://doi.org/10.5281/zenodo.5083813>
- [2] Andriy Myronenko, Dong Yang, Yufan He, and Daguang Xu “Automated 3D Segmentation of Kidneys and Tumors in MICCAI KiTS 2023 Challenge” <https://arxiv.org/pdf/2310.04110v1.pdf>
- [3] <https://monai.medium.com/simplifying-3d-medical-imaging-with-monai-auto3dseg-4350d73008a7>
- [4] P Afshar, A Mohammadi and KN Plataniotis, "Brain tumor type classification via capsule networks", 2018 25th IEEE international conference on image processing (ICIP), pp. 3129-33, 2018.
- [5] E. Calabrese, J. Villanueva-Meyer, J. Rudie, A. Rauschecker, U. Baid, S. Bakas, J. Mongan, C. Hess, and S. Cha, “The university of california san francisco preoperative diffuse glioma (ucsf-pdgm) mri dataset,” 2021.
- [6] U.Baid, et al., The RSNA-ASNR-MICCAI BraTS 2021 Benchmark on Brain Tumor Segmentation and Radiogenomic Classification, arXiv:2107.02314, 2021.
- [7] Myronenko, A.: 3D MRI brain tumor segmentation using autoencoder regularization. In: International MICCAI Brainlesion Workshop. pp. 311–320. Springer (2018)
- [8] He, Y., Yang, D., Roth, H., Zhao, C., Xu, D.: Dints: Differentiable neural network topology search for 3d medical image segmentation. In: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. pp. 5841–5850 (2021)
- [9] Hatamizadeh, A., Nath, V., Tang, Y., Yang, D., Roth, H.R., Xu, D.: Swin unetr: Swin transformers for semantic segmentation of brain tumors in mri images. In: International MICCAI Brainlesion Workshop. pp. 272–284. Springer (2021)
- [10] Tang, Y., Yang, D., Li, W., Roth, H.R., Landman, B., Xu, D., Nath, V., Hatamizadeh, A.: Self-supervised pre-training of swin transformers for 3d medical image analysis. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. pp. 20730–20740 (2022)
- [11] Antonelli, M., Reinke, A., Bakas, S., Farahani, K., Kopp-Schneider, A., Landman, B.A., Litjens, G., Menze, B., Ronneberger, O., Summers, R.M., et al.: The medical segmentation decathlon. Nature communications 13(1), 4128 (2022)
- [12] Fabian Isensee, Paul F. Jäger, Peter M. Full, Philipp Vollmuth, and Klaus H. Maier-Hein, “nnU-Net for Brain Tumor Segmentation” <https://arxiv.org/pdf/2011.00848.pdf>
- [13] F. Isensee, P. F. Jäger, S. A. Kohl, J. Petersen, and K. H. Maier-Hein, “Automated design of deep learning methods for biomedical image segmentation,” arXiv preprint arXiv:1904.08128, 2019.
- [14] Theophaste Henry, Alexandre Carre, Marvin Lerousseau, Theo Estienne, Charlotte Robert, Nikos Paragios and Eric Deutsch “Brain tumor segmentation with self-ensembled, deeply-supervised 3D U-net neural networks: a BraTS 2020 challenge solution” <https://arxiv.org/pdf/2011.01045.pdf>
- [15] BharathSimhaReddy Maram and Pooja Rana, “Brain Tumour Detection on BraTS 2020 Using U-Net” 2021 9th International Conference on Reliability, Infocom Technologies and Optimization (Trends and Future Directions) (ICRITO) Amity University, Noida, India. Sep 3-4, 2021
- [16] Haytham Al Ewaidat, Youness El Brag, Ahmad Wajeeh Yousef E’layan, Ali Almakhadme , “Training Strategies for Brain Tumor Segmentation in 3D Volumetric Data: The Pipelines Approach to the BraTS 2020 Challenge” September 2023
- [17] Harsh Garg, Ramavath Vasanth Naik, Tarun Harishchandra Pal, Mohit Kumar Mina, Anjali Gautam, “Brain Tumor Segmentation using the Modified UNET Architecture” 2023 IEEE 7th Conference on Information and Communication Technology (CICT-2023)
- [18] Lei Wang; Mingtao Liu, Yunyu Wang, Xianbiao Bai, MengJie Zhu, Fuchun Zhang, “A multi-scale method based on U-Net for brain tumor segmentation” 2022 7th International Conference on Communication, Image and Signal Processing (CCISP).
- [19] Wei-An Yang, Devin Lautan, Tong-Wei Weng, Wan-Chun Lin, Yamin Kao, Chien-Chang Chen, “Global Convolutional Self-Action Module for Fast Brain Tumor Image Segmentation” IEEE Transactions on Emerging Topics in Computational Intelligence ( Early Access ).
- [20] Aarif Raza and Mohammad Farukh Hashmi, “Multiclass Tumor Segmentation From Brain MRIs Using GARU-Net: Gelu Activated Attention Aware Res-3DUNET for Adaptive Feature Pooling”, IEEE Sensors Letters ( Volume: 8, Issue: 4, April 2024)
- [21] Smarta Sanguia , Tamim Iqbal , Piyush Chandra Chandraa , Swarup Kr Ghosha, Anupam Ghosh, “3D MRI Segmentation using U-Net Architecture for the detection of Brain Tumor” Procedia Computer Science 218 (2023) 542–553
- [22] Mostafa, A.M.; Zakariah, M.; Aldakheel, E.A. Brain Tumor Segmentation Using Deep Learning on MRI Images. Diagnostics 2023, 13, 1562. <https://doi.org/10.3390/diagnostics13091562>